

1. 如何完成第一个挑战

刚开始我对 SGLang 的流程并不是很熟悉，对很多专业名词都感到陌生。所以我使用了 AI 来帮助我理解一些不熟悉的概念和排查错误。例如遇到 CUDA、FlashInfer 相关报错时，我会把终端中的错误信息提供给 AI，让 AI 帮我分析可能的原因，然后根据建议逐步检查 CUDA 版本、相关库文件以及环境变量。接着我按照作业要求一步一步搭建环境，并尝试让 SGLang 正常运行。环境搭建完成后，我先启动 Qwen/Qwen3-0.6B 模型，然后通过 `/v1/models` 检查模型是否正常加载，最后使用 OpenAI 兼容接口发送了一次实际的推理请求，确认服务可以正常返回结果。完成单次推理之后，我又按照作业要求使用 Mooncake FAST'25 的 trace 数据进行测试。我先读取 trace 中的数据，然后利用 AI 编写 Python 脚本生成对应的模拟请求，并加入 Poisson 到达过程。第一次运行后发现部分请求的输入长度超过当前模型能够处理的范围，因此对程序进行了调整，增加了输入长度限制。之后重新运行，最终成功完成了 10 个请求的测试。

2. 最困难的地方及解决方法

我认为最困难的部分是 SGLang 启动过程中出现的相关问题。一开始 SGLang 无法正常启动，终端出现了 CUDA 编译器、CUDA Toolkit 以及链接库相关的报错。刚看到这些错误时，我并不知道具体是哪一部分出了问题。后来通过查询资料教程以及询问 AI 后逐步发现不同 CUDA 组件之间存在版本不一致的情况。之后我重新调整了 CUDA 相关组件的版本，并检查动态库路径和头文件路径。在解决库文件无法找到的问题时，我又检查了实际的 CUDA 文件目录，并对环境变量进行了调整。处理完这些问题后，终于成功启动 SGLang。

3. 启发

(1) 首先要明确问题到底是什么，不能一开始莽撞地就动手。确定问题以后，需要查找相关资料，善于查找方法，了解目前已经有了哪些方法，再根据自己的任务选择合适的技术路线。

(2) 实验过程中不可能一次就得到最终结果，通常需要不断发现问题、修改方案、重新运行和分析结果。因此，除了编程能力以外，排查问题和分析实验结果的能力也非常重要。

这次作业让我了解到一个完整的在线推理过程涉及多个环节。通过自己搭环境、处理报错和运行，对这些概念的理解比单纯看资料更深刻。同时我也认识到做一个新的研究任务时，可以借助 AI 帮助自己快速理解资料和排查问题，但不能完全依赖 AI。更重要的是自己动手验证、分析结果，并在一次次实验中不断修改和完善方案。