

截图一

```
pip(sqlang-env) syy@LAPTOP-OR3K1PQ8:~$ curl http://127.0.0.1:30000/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "Qwen/Qwen3-0.6B",
  "messages": [
    {
      "role": "user",
      "content": "请用一句话回答：什么是人工智能？"
    }
  ],
  "temperature": 0.2,
  "max_tokens": 128,
  "chat_template_kwargs": {
    "enable_thinking": false
  }
},
{"id":"409f0e475d8a4432a870ae43d66e7978","object":"chat.completion","created":1790416536,"model":"Qwen/Qwen3-0.6B","choices":[{"index":0,"message":{"role":"assistant","content":"人工智能（Artificial Intelligence, AI）是指通过计算机系统模拟人类智能的能力，包括学习、推理、感知、决策等能力。","reasoning_content":null,"tool_calls":null,"logprobs":null,"finish_reason":"stop","matched_stop":151645}],"usage":{"prompt_tokens":20,"total_tokens":49,"completion_tokens":29,"prompt_tokens_details":null,"reasoning_tokens":0},"metadata":{"weigh
sqlang-env) syy@LAPTOP-OR3K1PQ8:~$ }
```

截图二

```
=====
Mooncake FAST'25 Trace + Poisson Workload
=====
Trace文件: /home/syy/Mooncake/FAST25-release/arxiv-trace/mooncake_trace.jsonl
模型: Qwen/Qwen3-0.6B
测试请求数: 10
最大输入Token: 20800
平均请求到达间隔: 1.00 秒
Poisson lambda: 1.00 请求/秒
=====

正在加载 tokenizer...
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Tokenizer加载完成

成功读取 Trace 请求: 10 条

正在生成 Poisson 请求到达时间...
Poisson 到达时间生成完成

请求到达时间:
请求 01 | arrival_time = 0.000s | interval = 0.000s
请求 02 | arrival_time = 0.127s | interval = 0.127s
请求 03 | arrival_time = 0.825s | interval = 0.698s
请求 04 | arrival_time = 1.542s | interval = 0.717s
请求 05 | arrival_time = 3.508s | interval = 1.966s
请求 06 | arrival_time = 3.617s | interval = 0.108s
请求 07 | arrival_time = 3.869s | interval = 0.253s
请求 08 | arrival_time = 4.788s | interval = 0.919s
请求 09 | arrival_time = 5.601s | interval = 0.813s
请求 10 | arrival_time = 7.131s | interval = 1.530s
=====

开始发送 Workload
=====

请求 01 | Trace input=6755 | Trace output=500
计划到达时间: 0.000s
实际到达时间: 0.000s
状态: SUCCESS
实际输入 tokens: 6767
实际输出 tokens: 99
finish_reason: stop
Latency: 1.617s

=====

请求 02 | Trace input=7319 | Trace output=490
计划到达时间: 0.127s
实际到达时间: 1.618s
状态: SUCCESS
实际输入 tokens: 7331
实际输出 tokens: 129
finish_reason: stop
Latency: 1.018s

=====

请求 03 | Trace input=7234 | Trace output=794
计划到达时间: 0.825s
实际到达时间: 2.637s
状态: SUCCESS
实际输入 tokens: 7246
实际输出 tokens: 98
finish_reason: stop
Latency: 0.724s

=====

请求 04 | Trace input=2287 | Trace output=316
计划到达时间: 1.542s
实际到达时间: 3.362s
状态: SUCCESS
实际输入 tokens: 2299
实际输出 tokens: 194
finish_reason: stop
Latency: 1.061s
```

=====

请求 05 | Trace input=9013 | Trace output=3
计划到达时间: 3.508s
实际到达时间: 4.424s
状态: SUCCESS
实际输入 tokens: 9025
实际输出 tokens: 3
finish_reason: length
Latency: 0.249s

=====

请求 06 | Trace input=6506 | Trace output=3
计划到达时间: 3.617s
实际到达时间: 4.674s
状态: SUCCESS
实际输入 tokens: 6518
实际输出 tokens: 3
finish_reason: length
Latency: 0.036s

=====

请求 07 | Trace input=4824 | Trace output=173
计划到达时间: 3.869s
实际到达时间: 4.712s
状态: SUCCESS
实际输入 tokens: 4836
实际输出 tokens: 121
finish_reason: stop
Latency: 0.807s

=====

请求 08 | Trace input=3119 | Trace output=20
计划到达时间: 4.788s
实际到达时间: 5.520s
状态: SUCCESS
实际输入 tokens: 3131
实际输出 tokens: 20
finish_reason: length
Latency: 0.130s

=====

请求 09 | Trace input=23090 | Trace output=453
计划到达时间: 5.601s
实际到达时间: 5.651s
状态: SKIPPED
原因: input_length=23090 > 最大允许长度=20800

=====

请求 10 | Trace input=3135 | Trace output=19
计划到达时间: 7.131s
实际到达时间: 7.154s
状态: SUCCESS
实际输入 tokens: 3147
实际输出 tokens: 19
finish_reason: length
Latency: 0.129s

=====

实验结果

=====

总请求数: 10
成功请求数: 9
跳过请求数: 1
失败请求数: 0
总输入 tokens: 50300
总输出 tokens: 686
总请求 Latency: 5.770 秒
平均请求 Latency: 0.641 秒
平均输出吞吐量: 118.88 tokens/s

=====

结果文件

=====

JSON: /home/syy/trace_results_poisson.json